Московский государственный технический университет им. Н.Э. Баумана

Факультет «Информатика, искусственный интеллект и системы управления»

Кафедра «Системы обработки информации и управления»

Курс «Методы машинного обучения в АСОИУ»

Отчет по лабораторной работе №1

«Создание "истории о данных" (Data Storytelling)»

Выполнил:

студент группы ИУ5-22М

Коценко А.А.

Подпись и дата:

Проверил:

преподаватель каф. ИУ5

Гапанюк Ю.Е.

Подпись и дата:

Москва, 2023 г.

Лабораторная работа №1

Создание "истории о данных" (Data Storytelling)

Коценко Антон Александрович ИУ5-22М

Цель лабораторной работы

Изучение различных методов визуализация данных и создание истории на основе данных.

Задание

- Выбрать набор данных (датасет).
- Создать "историю о данных" в виде юпитер-ноутбука, с учетом следующих требований.
    1. История должна содержать 5 шагов. Каждый шаг содержит график и его текстовую интерпретацию.
    2. На каждом шаге наряду с удачным итоговым графиком рекомендуется в юпитер-ноутбуке оставлять результаты предварительных "неудачных" графиков.
    3. Не рекомендуется повторять виды графиков, желательно создать 5 графиков различных видов.
    4. Выбор графиков должен быть обоснован использованием методологии data-to-viz. Рекомендуется учитывать типичные ошибки построения выбранного вида графика по методологии data-to-viz. Если методология Вами отвергается, то просьба обосновать Ваше решение по выбору графика.
    5. История должна содержать итоговые выводы. В реальных "историях о данных" именно эти выводы представляют собой основную ценность для предприятия.
- Сформировать отчет и разместить его в своем репозитории на github.

Выбор датасета

Описание атрибутов

- MedInc — Средний доход для домохозяйств в пределах квартала домов
- HouseAge — Возраст домов в пределах квартала (меньшее число означает более новое здание)
- AveRooms — Среднее количество комнат в пределах квартала.
- AveBedrms — Среднее количество спален в пределах квартала.
- Population — Общее количество людей, проживающих в пределах квартала.
- AveOccup — Среднее количество участников домохозяйства.

- Latitude — Показатель того, насколько далеко к северу находится дом (чем выше значение, тем дальше к северу).
- Longitude — Показатель того, насколько далеко на запад находится дом (чем более отрицательное значение, тем дальше на запад).
- MedHouseValue —Средняя стоимость жилья для домохозяйств в пределах квартала.

Ввод [1]:

```
from sklearn.datasets import fetch_california_housing
df = fetch_california_housing(as_frame=True).frame
df
```

Out[1]:

	MedInc	HouseAge	AveRooms	AveBedrms	Population	AveOccup	Latitu
0	8.3252	41.0	6.984127	1.023810	322.0	2.555556	37
1	8.3014	21.0	6.238137	0.971880	2401.0	2.109842	37
2	7.2574	52.0	8.288136	1.073446	496.0	2.802260	37
3	5.6431	52.0	5.817352	1.073059	558.0	2.547945	37
4	3.8462	52.0	6.281853	1.081081	565.0	2.181467	37
...	...	...	...	...	...	...	
20635	1.5603	25.0	5.045455	1.133333	845.0	2.560606	39
20636	2.5568	18.0	6.114035	1.315789	356.0	3.122807	39
20637	1.7000	17.0	5.205543	1.120092	1007.0	2.325635	39
20638	1.8672	18.0	5.329513	1.171920	741.0	2.123209	39
20639	2.3886	16.0	5.254717	1.162264	1387.0	2.616981	39

20640 rows × 9 columns

Ввод [2]:

```
df.info() # Prints the information about the dataframe
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 20640 entries, 0 to 20639
Data columns (total 9 columns):
 #   Column       Non-Null Count  Dtype  
---  ------       --------------  -----  
 0   MedInc       20640 non-null  float64
 1   HouseAge     20640 non-null  float64
 2   AveRooms     20640 non-null  float64
 3   AveBedrms    20640 non-null  float64
 4   Population   20640 non-null  float64
 5   AveOccup     20640 non-null  float64
 6   Latitude     20640 non-null  float64
 7   Longitude    20640 non-null  float64
 8   MedHouseVal  20640 non-null  float64
dtypes: float64(9)
memory usage: 1.4 MB
```

История о данных

Ввод [3]:

```
import numpy as np
import pandas as pd
import seaborn as sns
import geopandas as gpd
import matplotlib.pyplot as plt
import matplotlib.image as mpimg
from shapely.geometry import Point
%matplotlib inline
```

Первый шаг — Violin plot

Ввод [4]:

```
sns.violinplot(x=df['MedHouseVal'])
```

Out[4]:

```
<AxesSubplot:xlabel='MedHouseVal'>
```

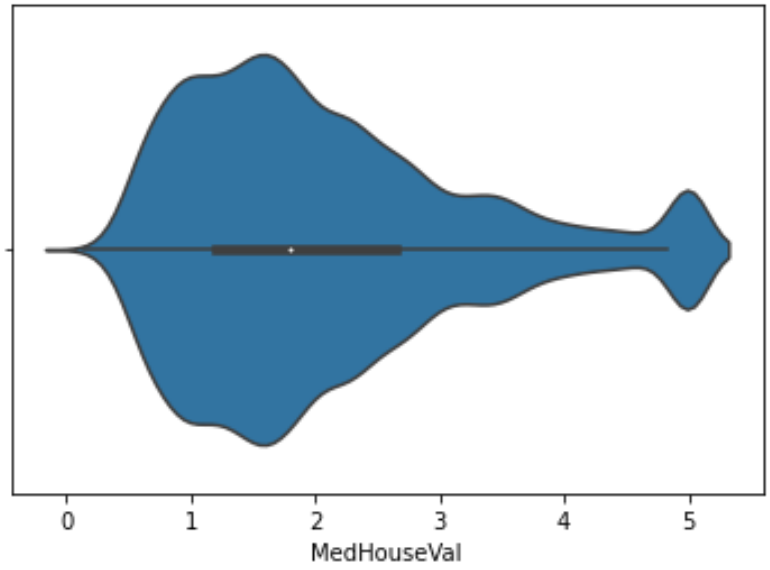

Второй шаг — Boxplot

Ввод [5]:

```
sns.boxplot(x=df['MedHouseVal'])
```

Out[5]:

```
<AxesSubplot:xlabel='MedHouseVal'>
```

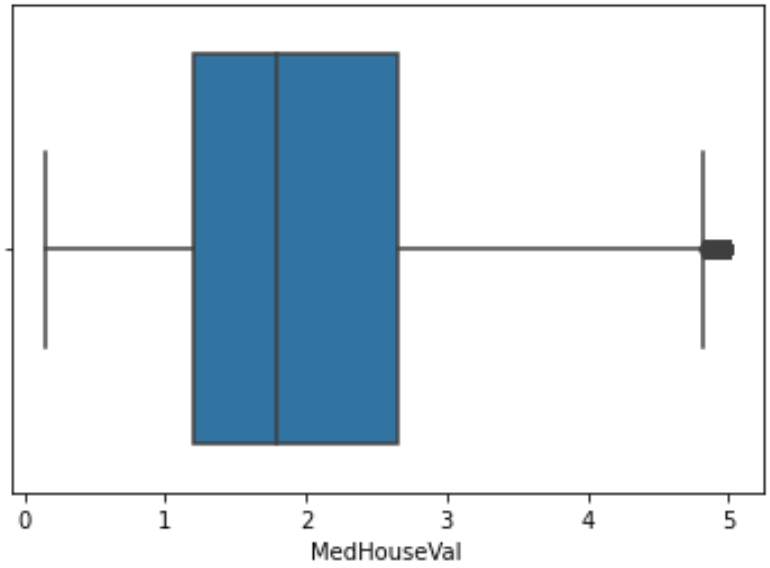

Третий шаг — Heatmap

- MedInc — Средний доход для домохозяйств в пределах квартала домов
- HouseAge — Возраст домов в пределах квартала (меньшее число означает более новое здание)
- AveRooms — Среднее количество комнат в пределах квартала.
- AveBedrms — Среднее количество спален в пределах квартала.
- Population — Общее количество людей, проживающих в пределах квартала.
- AveOccup — Среднее количество участников домохозяйства.
- Latitude — Показатель того, насколько далеко к северу находится дом (чем выше значение, тем дальше к северу).
- Longitude — Показатель того, насколько далеко на запад находится дом (чем более отрицательное значение, тем дальше на запад).
- MedHouseValue —Средняя стоимость жилья для домохозяйств в пределах квартала.

Ввод [6]:

```
plt.figure(figsize=(10,7))
sns.heatmap(df.corr(),cmap='RdBu',annot=True,fmt='.3f')
```

Out[6]:

```
<AxesSubplot:>
```

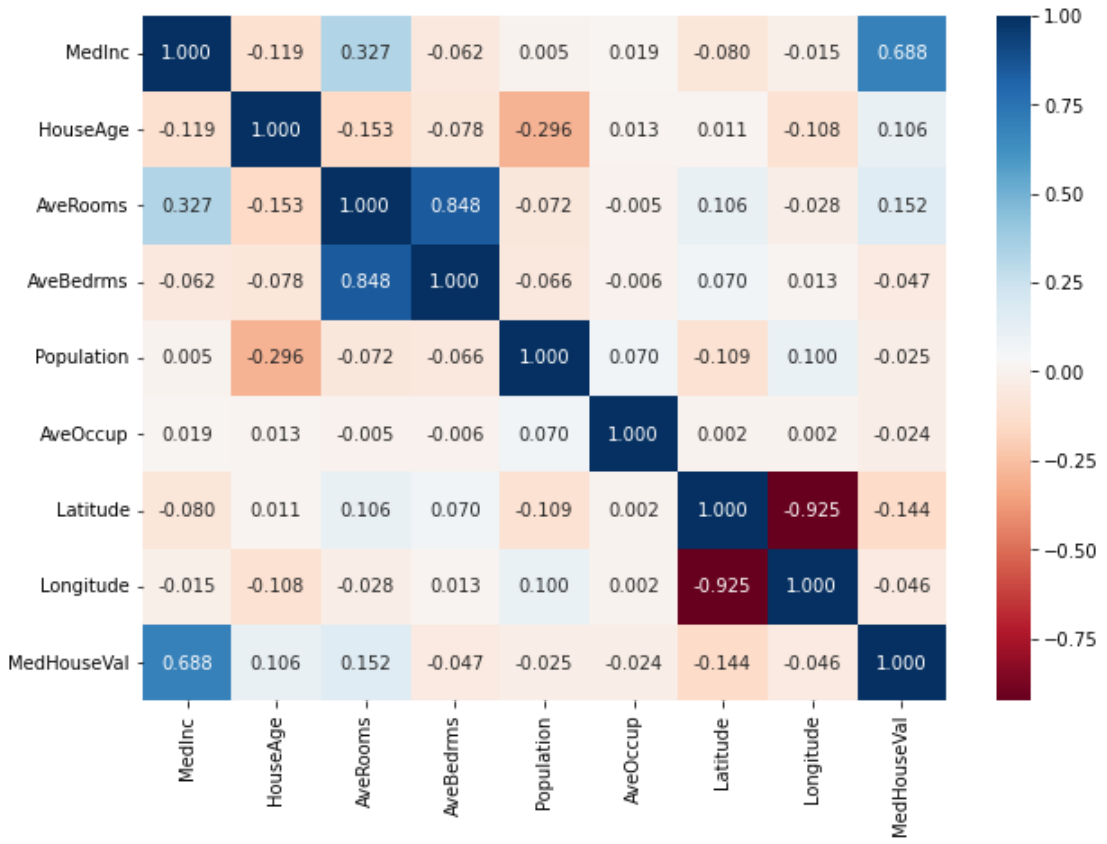

Четвертый шаг — Correlogram

Ввод [7]:

```
plt.figure(figsize=(12,12))
sns.pairplot(df)
```

Out[7]:

```
<seaborn.axisgrid.PairGrid at 0x281cda85bb0>
```

```
<Figure size 864x864 with 0 Axes>
```

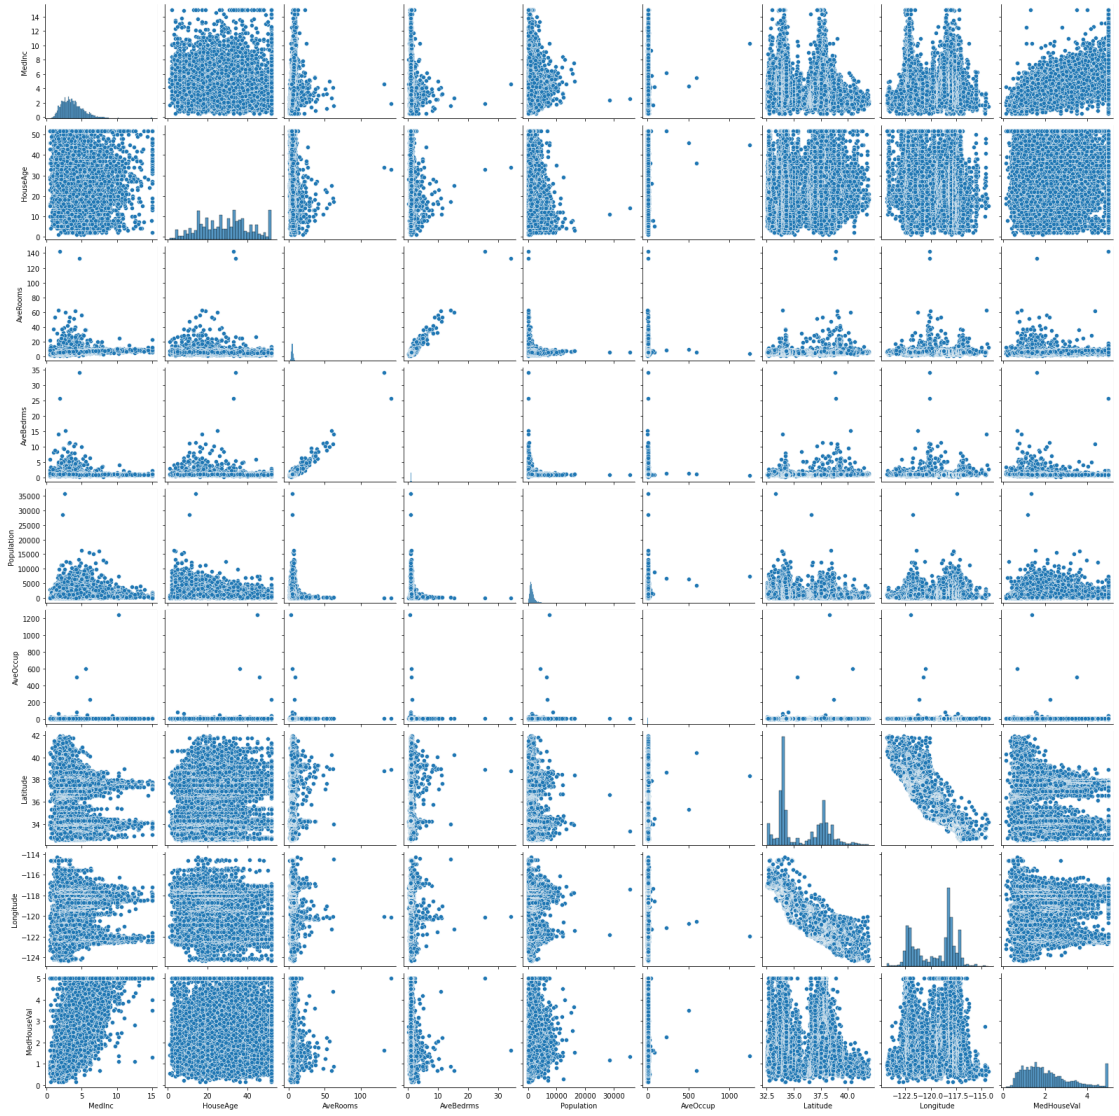

Пятый — Map

Ввод [8]:

```
# Средняя стоимость жилья для домохозяйств в пределах квартала.
geometry = [Point(xy) for xy in zip(df["Longitude"], df["Latitude"])]
geo_df = gpd.GeoDataFrame(df,geometry = geometry) #california_housing
geo_df.plot(column='MedHouseVal',legend=True, figsize=(18, 12),cmap='RdYlBu_r')
```

Out[8]:

```
<AxesSubplot:>
```

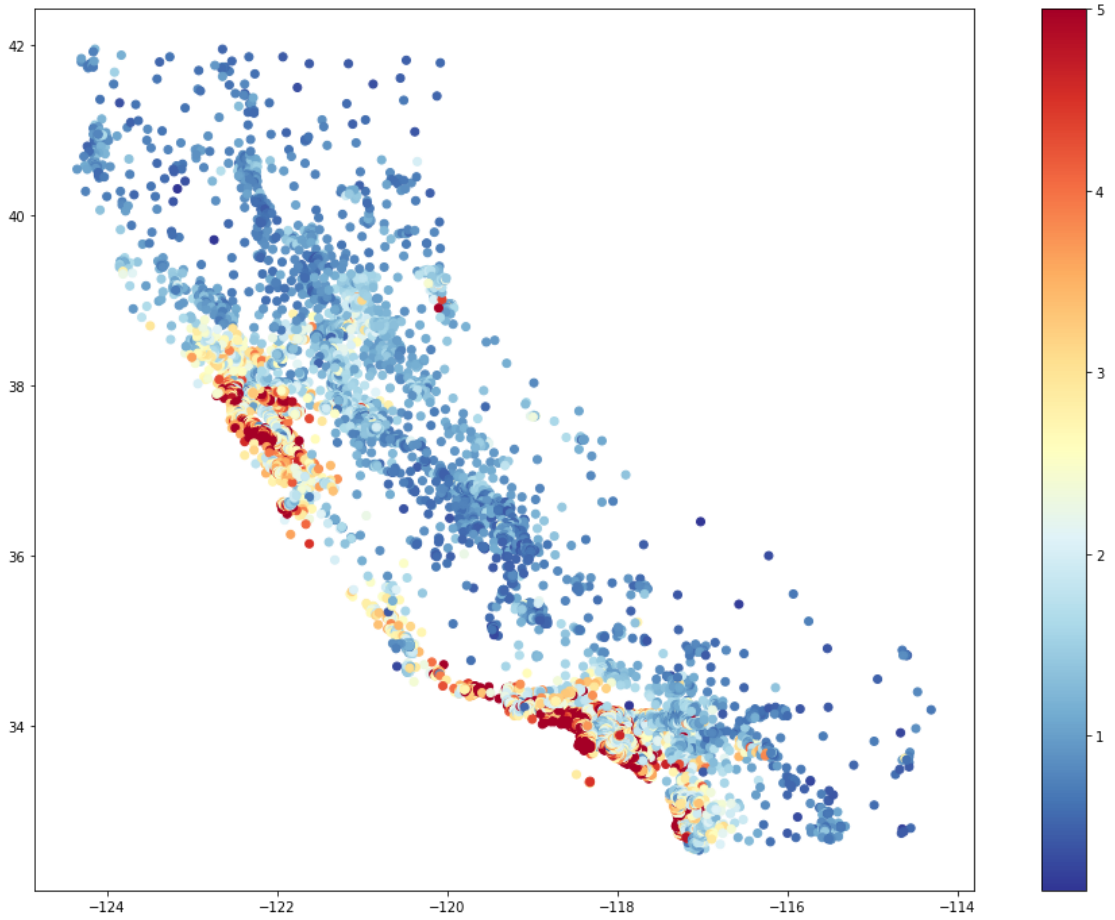

Ввод [9]:

```
plt.figure(figsize=(12,15))
img = mpimg.imread('california.png')
imgplot = plt.imshow(img)
```

Вывод к истории о данных

По Violin plot видно, что основная доля домов находится по стоимости от 0,5 до 2,5. По диаграммам Violin plot и Boxplot заметен выброс в районе 5. Наиболее вероятно примерно столько стоит элитная недвижимость. По тепловой карте понятно, что в основном между параметрами зависимость довольно низкая. Средняя зависимость между MedHouseVal и Medinc, высокая положительная зависимость между AveRooms и AveBedrms, а высокая отрицательная между Longitude и Latitude. В конце была построена карта, на которой видно, что на побережье Калифорнии недвижимость стоит существенно выше, чем в глубине штата.

Дополнительные карты

Ввод [10]:

```
# Средний доход для домохозяйств в пределах квартала домов
geo_df.plot(column='MedInc',legend=True, figsize=(18, 12),cmap='RdYlBu_r')
```

Out[10]:

```
<AxesSubplot:>
```

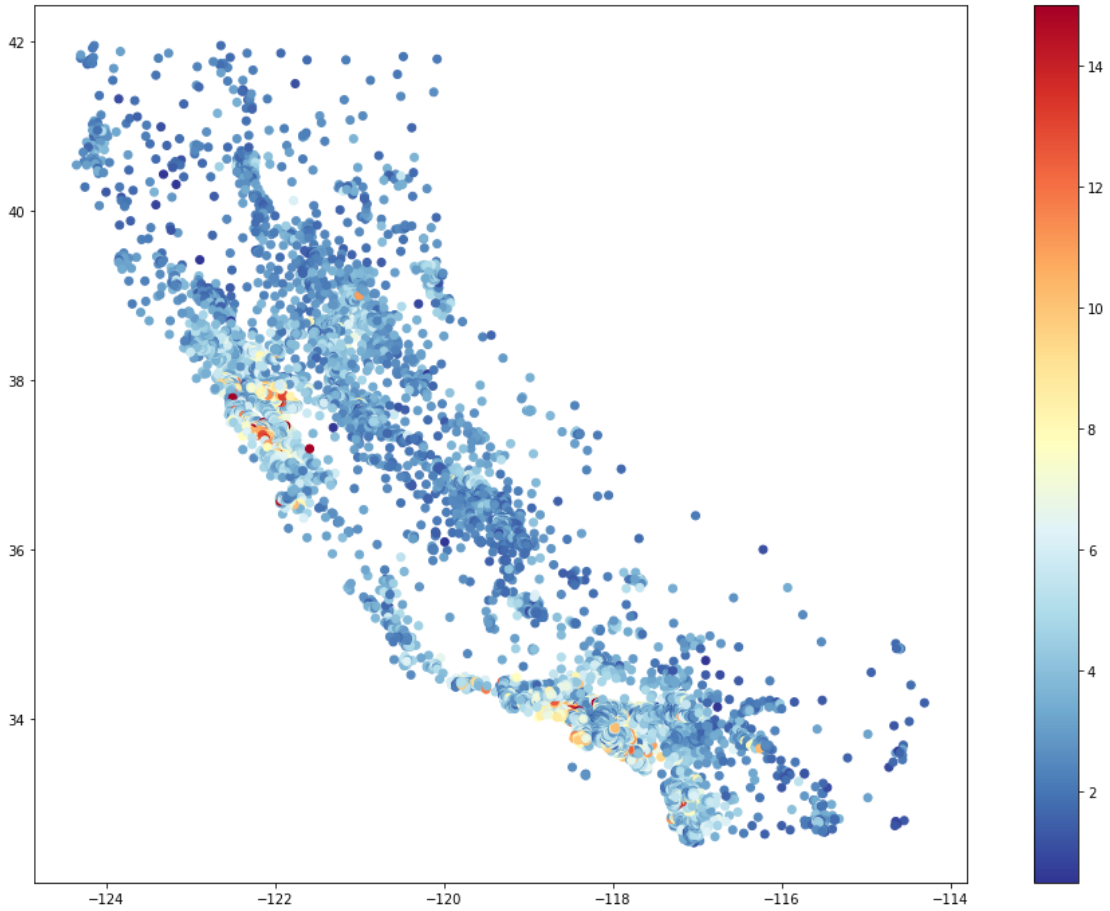

Ввод [11]:

```
# Возраст домов в пределах квартала (меньшее число означает более новое здание)
geo_df.plot(column='HouseAge',legend=True, figsize=(18, 12),cmap='RdYlBu_r')
```

Out[11]:

```
<AxesSubplot:>
```

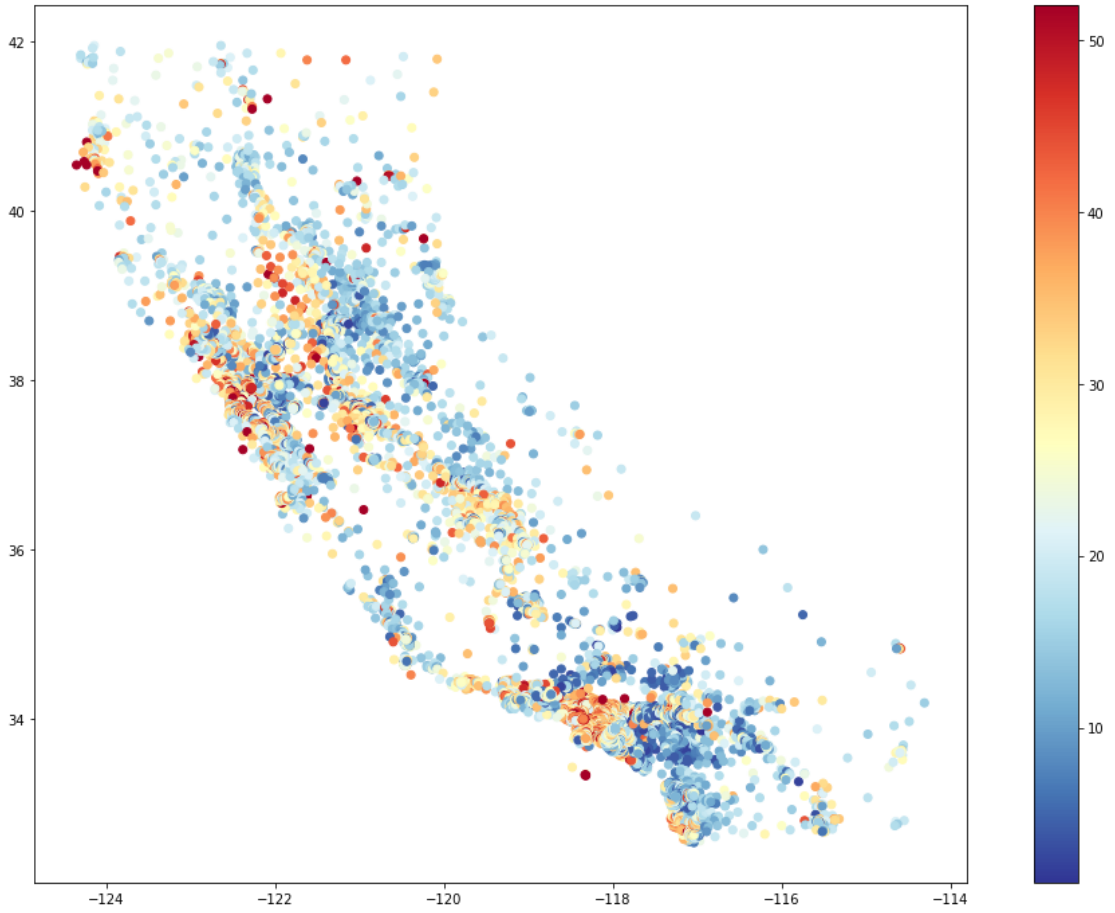

Ввод [12]:

```
# Среднее количество комнат в пределах квартала.
geo_df.plot(column='AveRooms',legend=True, figsize=(18, 12),cmap='RdYlBu_r')
```

Out[12]:

```
<AxesSubplot:>
```

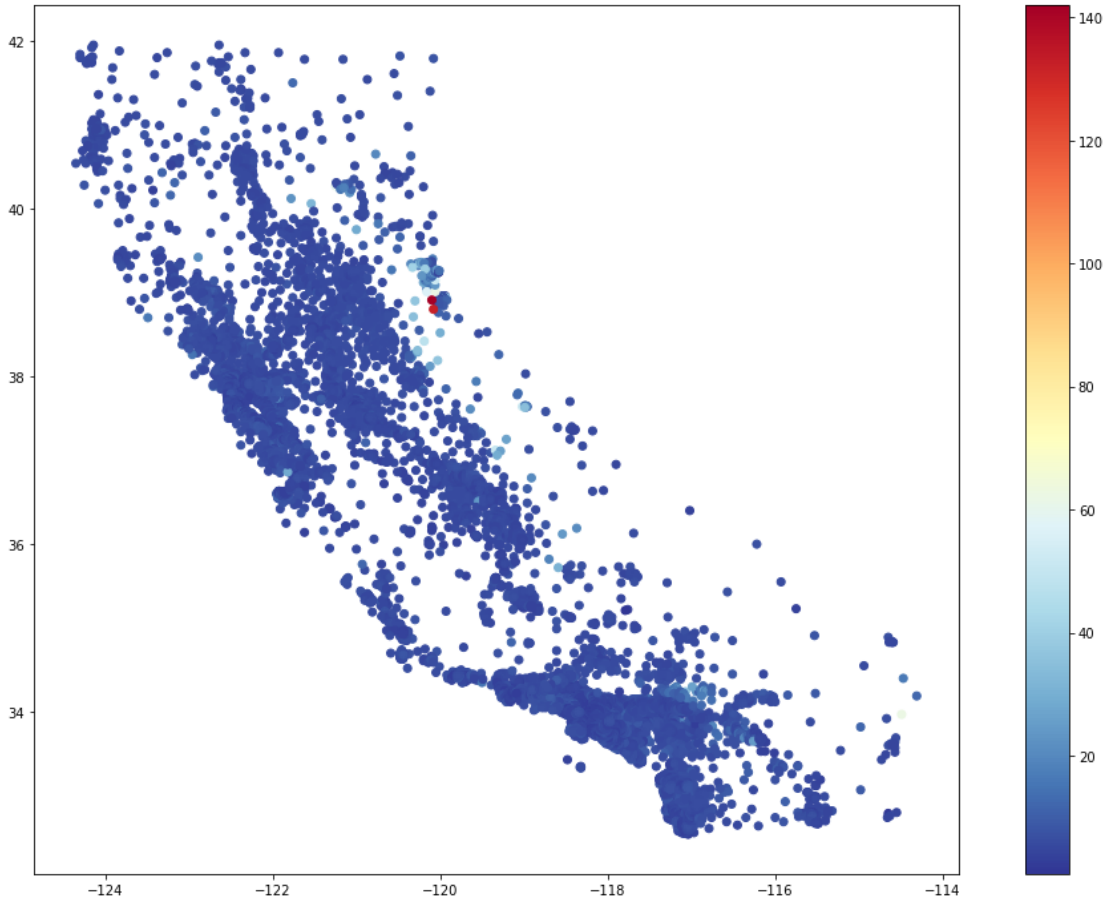

Ввод [13]:

```
# Среднее количество спален в пределах квартала.
geo_df.plot(column='AveBedrms',legend=True, figsize=(18, 12),cmap='RdYlBu_r')
```

Out[13]:

```
<AxesSubplot:>
```

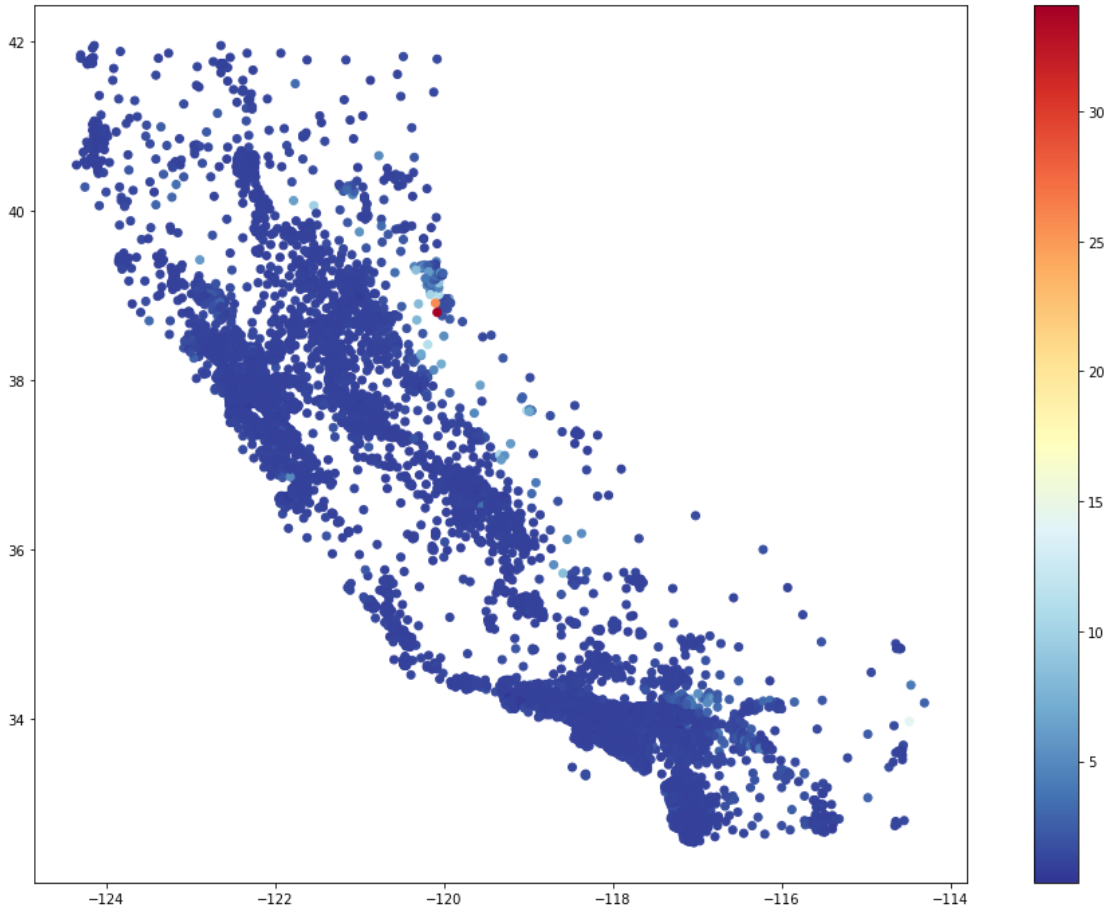

Ввод [14]:

```
# Общее количество людей, проживающих в пределах квартала.
geo_df.plot(column='Population',legend=True, figsize=(18, 12),cmap='RdYlBu_r')
```

Out[14]:

```
<AxesSubplot:>
```

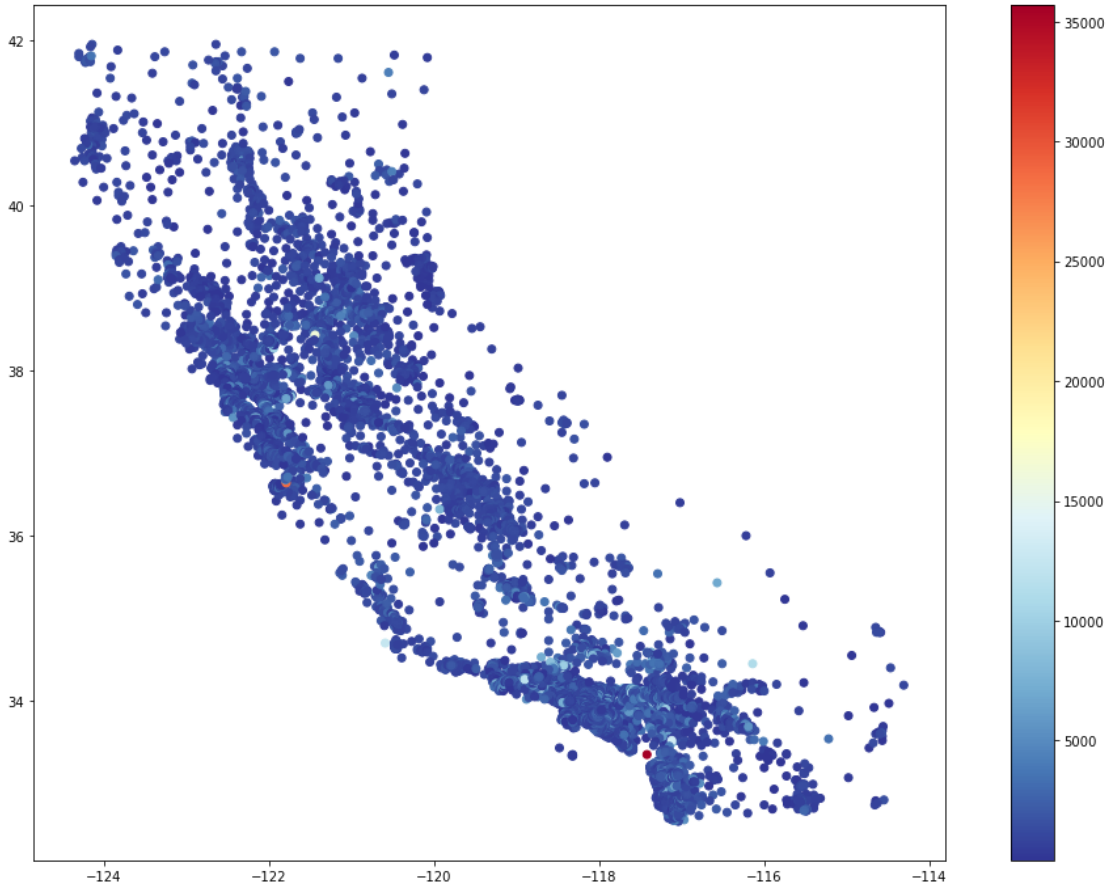

Ввод [15]:

```
# Среднее количество участников домохозяйства.
geo_df.plot(column='AveOccup',legend=True, figsize=(18, 12),cmap='RdYlBu_r')
```

Out[15]:
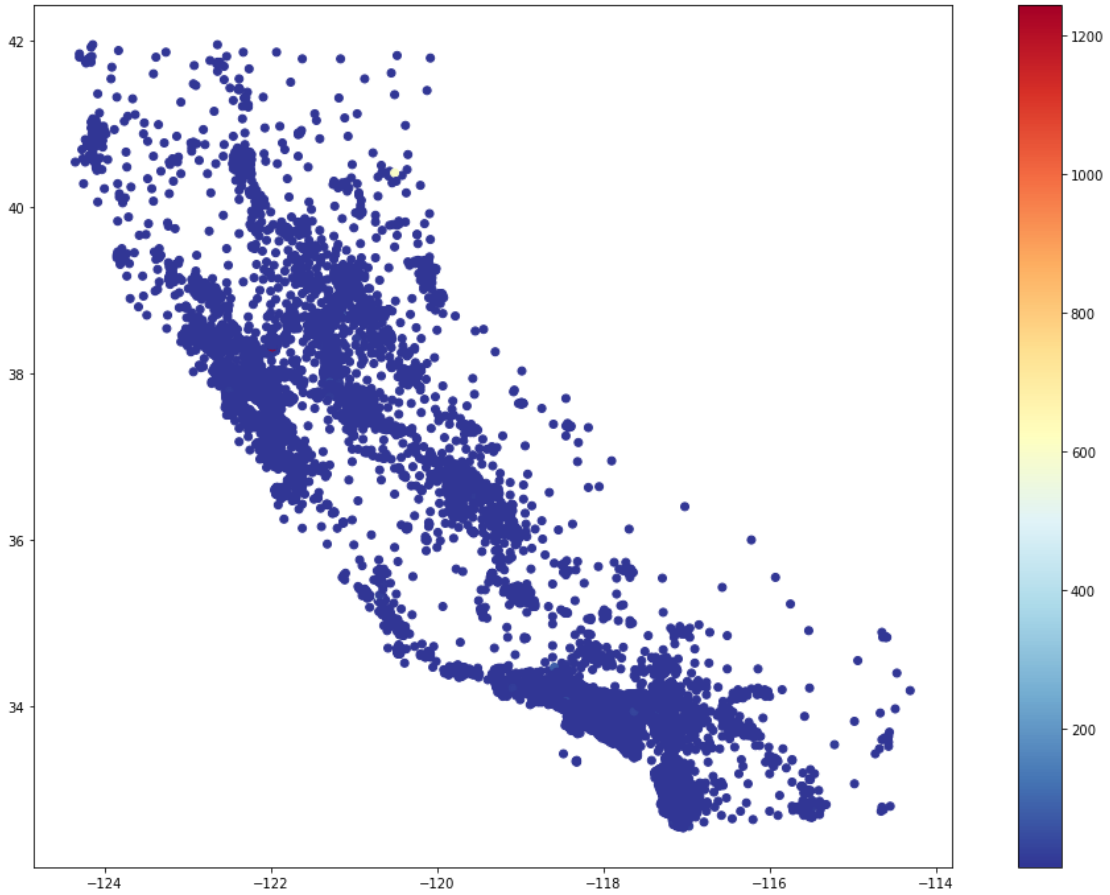
```
<AxesSubplot:>
```